

國立臺南大學資訊工程學系
116 級畢業專題報告

漸進式視覺證據驗證之零樣本開放詞彙三
維視覺定位

*PROVE-3D: Progressive Observation and
Verification with Evidence for Zero-Shot 3D Visual
Grounding*

專案編號：NUTN-CSIE-PRJ-116-009

組員：S11259013 羅暉嫻

S11259019 莊旻芳

S11259029 李安以

指導老師：林朝興 教授

中華民國 115 年 9 月

國立臺南大學資訊工程學系
畢業專題報告審定書

漸進式視覺證據驗證之零樣本開放詞彙三維視
覺定位

*PROVE-3D: Progressive Observation and
Verification with Evidence for Zero-Shot 3D Visual
Grounding*

學生 學號：S11259013 姓名：羅暉璋
 學號：S11259019 姓名：莊旻芳
 學號：S11259029 姓名：李安以

所提之報告內容符合本學系大學部畢業專題實作標準。

指導教授：林朝興 教授

系主任：林朝興 教授

中華民國 115 年 9 月

摘要

近年來，視覺語言模型（Vision-Language Models, VLMs）的發展，使得在不需要針對特定三維任務進行訓練的情況下，執行零樣本三維視覺定位（zero-shot 3D visual grounding）成為可能。然而，現有的多視角觀測可能無法針對包含目標屬性、參考物件與空間關係的查詢提供足夠的視覺證據。我們提出 PROVE-3D（Progressive Observation and Verification with Evidence，基於證據的漸進式觀測與驗證），一套零樣本三維視覺定位框架，整合了增量式多視角觀測、物件層級驗證，以及自適應視覺證據取得。當累積的證據足以確認目標後，Early-stop 策略便會終止後續的場景處理。最後，系統會將已驗證的候選物件投影並融合至三維空間中，以估計其三維邊界框。PROVE-3D 在 ScanRefer 上取得整體 Acc@0.25 54.8%，並在 Nr3D 上取得 55.6% 的 top-1 定位準確率。在 ScanRefer 上，Early-stop 僅使用 Full-scene 所取樣 Reader 觀測預算的 62.93%，同時保留 Full-scene 95.62% 的 Acc@0.25 表現，顯示其能在三維定位效能與觀測需求之間取得有效的權衡。程式碼將公開於：

<https://github.com/Min-FangChuang/PROVE-3D>

關鍵詞：三維視覺定位、零樣本學習、視覺語言模型、多視角感知、開放詞彙

PROVE-3D: Progressive Observation and Verification with Evidence for Zero-Shot 3D Visual Grounding

ABSTRACT

Recent advances in Vision-Language Models (VLMs) have enabled zero-shot 3D visual grounding without task-specific 3D training. However, existing multi-view observations may not provide sufficient visual evidence for queries involving target attributes, reference objects, and spatial relations. We propose PROVE-3D (Progressive Observation and Verification with Evidence), a zero-shot 3D visual grounding framework that integrates incremental multi-view observation, object-level verification, and adaptive visual evidence acquisition. Once sufficient evidence has been accumulated to confirm the target, the Early-stop strategy terminates further scene processing. Finally, the verified candidate is projected and fused into 3D space to estimate its 3D bounding box. PROVE-3D achieves an overall Acc@0.25 of 54.8% on ScanRefer and a top-1 grounding accuracy of 55.6% on Nr3D. On ScanRefer, Early-stop consumes 62.93% of the sampled Reader observation budget while retaining 95.62% of the Full-scene Acc@0.25, demonstrating an effective trade-off between grounding performance and observation demand. Codes will be available at <https://github.com/Min-FangChuang/PROVE-3D>.

Keywords : 3D visual grounding, Zero-shot learning, Vision-Language Model, Multi-view perception, Open-vocabulary

致謝

本專題能夠順利完成，首先要特別感謝指導教授林朝興教授，在專題研究期間給予我們耐心且細心的指導。從研究方向的確立、問題的釐清、方法架構的設計，到系統實作、實驗規劃與結果分析，教授都提供了許多具體而寶貴的建議。尤其在研究過程中遇到方法設計不夠完善、實驗結果未如預期，或論述不夠清楚時，教授總能從不同角度提醒我們重新檢視問題，協助我們找出需要改進的地方，讓整體研究能夠逐步修正並更加完整。

在論文撰寫與研究成果整理的過程中，教授也多次針對研究動機、方法合理性、實驗設計以及結果呈現給予建議，使我們不只是完成系統實作，也能更清楚地說明研究所要解決的問題與方法的價值。從專題初期的方向討論，到後續一次次的修改與調整，教授投入了許多時間與心力陪伴我們完成這項研究。在此誠摯感謝林朝興教授一路以來的指導、提醒與鼓勵，讓本專題得以順利完成。

羅暉偉 莊旻芳 李安以 謹致
國立臺南大學資訊工程學系
中華民國 115 年 9 月

目錄

摘要	i
ABSTRACT	ii
致謝	iii
目錄	iv
表目錄	vi
圖目錄	vii
一、緒論	1
1.1 研究動機	1
1.2 研究目的	2
1.3 分工表	4
二、相關研究	4
2.1 零樣本三維視覺定位方法	4
2.2 場景表示與 VLM 推理範圍	4
2.3 視覺證據涵蓋與自適應觀測	5
三、方法與流程	6
3.1 系統架構	6
3.2 觀測單元讀取與候選建立(Read Unit & Create Candidate)	7
3.3 候選精煉 (Candidate Refinement)	7
3.4 2D-to-3D 映射 (2D-to-3D Mapping)	9
四、實驗結果	10
4.1 實驗設定	10
4.1.1 資料集與評估指標	10
4.1.2 實作設定	10
4.1.3 視角選擇設定	11
4.2 三維視覺定位結果	11
4.2.1 ScanRefer 實驗結果	11
4.2.2 Nr3D 實驗結果	12
4.3 Early-stop 策略分析	13
4.3.1 觀測效率	13

4.4 三維定位精度分析	14
4.5 消融實驗	14
4.5.1 元件貢獻	14
4.5.2 環境證據分析	15
4.5.3 動作選擇策略	16
五、結論與未來展望	16
參考文獻	17
附錄	19

表目錄

表 1	分工表	3
表 2	ScanRefer 三維視覺定位結果 (%).....	11
表 3	Nr3D 三維視覺定位結果 (%).....	12
表 4	ScanRefer 嚴格 IoU 條件下的準確率保留比例 (%)	14
表 5	元件消融實驗 (%).....	14
表 6	環境證據消融實驗 (%).....	15
表 7	額外觀測動作選擇策略消融實驗 (%).....	16

圖目錄

圖 1	傳統方法與 PROVE-3D 的比較差異	2
圖 2	PROVE-3D 整體系統流程	6
圖 3	Early-stop 相對於 Full-scene 的觀測量與準確率保留比例	13

一、緒論

1.1 研究動機

三維視覺定位 (3D Visual Grounding, 3DVG) [1] 的目標，是根據自然語言描述，在三維環境中找出使用者所指定的目標物件。與一般物件辨識不同，三維視覺定位所處理的描述不僅包含物件類別，也可能涉及物件的外觀屬性、參考物件以及彼此之間的空間關係[2]。例如當使用者描述「桌子旁邊的椅子」時，系統除了需要辨識椅子本身，也必須理解桌子的位置以及兩者之間的相對關係。因此，三維視覺定位同時涉及語意理解、視覺辨識與空間關係推理，是連結自然語言與三維場景理解的重要研究課題。

傳統三維視覺定位方法多仰賴特定任務的訓練資料與具有人工標註的三維場景，藉此學習語言描述與三維物件之間的對應關係[3], [4]。然而，大規模三維資料的蒐集與標註需要投入大量人力與成本，同時也使模型容易受到既有訓練類別與場景的限制，當面對未曾出現在訓練資料中的物件或環境時，其泛化能力仍受到限制。近年視覺語言模型 (Vision-Language Model, VLM) 的快速發展，使模型能利用大規模預訓練所獲得的視覺與語言知識，在不針對三維視覺定位任務額外訓練的情況下進行零樣本 (zero-shot) 推理，因此逐漸成為三維視覺定位的重要研究方向[5], [6], [7]。

如圖 1 所示，傳統方法主要從既有多視角影像中篩選包含目標物件的視角，再交由 VLM 進行判斷。然而，三維場景中的物件通常無法由單一影像完整呈現，因此現有零樣本方法大多利用多視角影像補充單一視角缺少的資訊[6], [7], [8]。雖然多視角觀測能提供更多目標物件資訊，但「具有多張影像」並不代表這些影像一定包含完成語言查詢所需要的視覺證據。現有方法多半依據目標物件或物件候選是否出現在畫面中來選取觀測視角，使取得的影像主要集中於目標本身。若查詢只要求辨識物件類別，清楚的目標視角可能已足以完成判斷；但當描述涉及顏色等目標屬性、其他參考物件，或「上方」、「旁邊」、「兩個物件之間」等空間關係時，僅觀察目標物件往往不足以驗證完整的語言條件。




圖 1 傳統方法與 PROVE-3D 的比較差異

因此，本研究認為零樣本三維視覺定位中的關鍵問題，不只是「應該取得多少視角」，而是目前取得的視角是否包含足以驗證語言描述的視覺證據。若系統在推理開始前即固定所有觀測，不但可能缺少真正需要的環境資訊，也可能處理大量對目前查詢沒有直接幫助的影像。相較之下，若能在定位過程中持續判斷現有證據是否充分，並針對尚未確認的條件取得額外觀測，便能使觀測範圍依照不同語言查詢的需求動態調整。

基於上述問題，本研究將三維視覺定位重新視為一個 **漸進式觀測與驗證 (incremental observation and verification)** 的過程。系統在逐步取得 RGB-D 多視角觀測的同時建立物件候選，並利用視覺語言模型驗證候選是否符合查詢中的目標屬性、參考物件及空間關係。當現有資訊不足時，再依據缺少的視覺證據補充新的觀測；當證據已足以確認目標時，則可提早停止後續場景處理。藉此，希望在維持三維定位能力的同時，降低不必要的場景觀測與推理成本。

1.2 研究目的

基於上述研究動機，本研究提出 **PROVE-3D (Progressive Observation and Verification with Evidence)**，目標是在不進行特定三維視覺定位任務訓練的情況下，利用自然語言描述與多視角 RGB-D 觀測完成零樣本三維視覺定位。不同於將所有場景資訊一次提供給模型後再進行判斷，本研究希望讓系統隨著場景資訊逐步取得，同步建立候選物件、累積跨視角資訊並進行驗證，使觀測與推理能依照目前所需的證據動態進行。

我們在標準的三維視覺定位基準資料集上評估所提出的框架，使用自然語言指涉描述與多視角 RGB-D 觀測作為輸入[1], [3]。實驗主要評估定位準確率，並分析增量式觀測、物件層級精煉、證據引導的視角取得，以及不同終止策略對系統效能的影響。

此外，透過比較 Early-stop 與 Full-scene，進一步探討定位效能與完成定位所需場景資訊量之間的關係。

具體而言，本研究的研究目的可整理為以下四項：

1. **建立增量式多視角候選物件表示：**透過開放詞彙二維物件偵測取得可能的目標物件，並利用跨視角特徵匹配 (Cross-view Feature Matching)，將不同 RGB-D 視角中屬於同一實體物件的觀測逐步關聯，使候選物件能累積多視角視覺資訊，而非將每張影像中的偵測結果視為彼此獨立的物件。
2. **建立以視覺證據充分性為基礎的候選驗證機制：**利用 VLM 判斷候選物件是否符合自然語言查詢中的目標類別、外觀屬性、參考物件及空間關係。當現有資訊不足以完成判斷時，系統不立即排除候選，而是辨識尚缺少的證據，並透過周圍環境觀測或額外視角取得資訊後重新驗證。
3. **探討自適應觀測與提早終止機制：**本研究設計 Early-stop 與 Full-scene 兩種搜尋策略。Full-scene 會處理所有可取得的場景觀測後再進行最終選擇；Early-stop 則在候選已獲得足夠證據並被確認後立即停止後續場景處理。藉由兩者比較，分析三維視覺定位準確度與觀測需求之間的關係，探討是否能在不完整處理場景資訊的情況下維持有效的定位能力。
4. **完成物件層級的 2D-to-3D 定位：**在確認最終候選後，利用其多視角 segmentation mask、深度資訊、相機內參與相機位姿，將二維目標區域反投影至共同的三維座標系，融合並過濾多視角三維點，最後估計目標物件的三維邊界框，使系統由語言與二維視覺推理進一步得到實際的三維定位結果。

綜合而言，本研究的核心目的並非單純增加觀測影像數量，而是讓系統能夠根據語言查詢所需要的證據決定何時觀察、觀察哪些資訊，以及何時停止觀察。透過增量式候選建立、物件層級驗證、自適應視覺證據取得與 2D-to-3D 映射，建立一套兼顧三維定位準確度與觀測效率的零樣本三維視覺定位框架。

1.3 分工表

表一 分工表

姓名	項目	百分比
羅暉偉	統籌、資料蒐集、設計規劃、2D→3D 映射、系統優化調整	33%
莊旻芳	統籌、資料蒐集、設計規劃、候選生 成、系統優化調整、消融實驗	34%
李安以	統籌、資料蒐集、設計規劃、輸入前 處理、系統優化調整	33%

二、相關研究

2.1 零樣本三維視覺定位方法

近年來，以視覺語言模型（Vision-Language Model, VLM）為基礎的零樣本三維視覺定位方法，主要透過多視角視覺資訊，將自然語言描述與三維場景中的物件建立對應關係。這類方法不需針對特定三維定位任務進行額外訓練，而是利用預訓練 VLM 所具備的視覺與語意理解能力完成目標辨識與定位[6], [7], [9], [10], [11], [12]。

VLM-Grounder [14] 直接在具有相機位姿資訊的場景影像上進行定位，並在辨識出目標後，進一步整合該目標的多視角觀測，以完成三維定位。SeqVLM [8] 則先建立三維物件候選(3D object proposals)，再為各候選整理相對應的多視角影像，讓 VLM 以物件為單位進行推理。這些研究顯示，將 VLM 的語意推理能力與多視角觀測資訊結合，能有效支援零樣本三維視覺定位，也使後續研究逐漸關注場景資訊應如何組織，以及 VLM 應以何種範圍進行推理。

2.2 場景表示與 VLM 推理範圍

不同零樣本三維視覺定位方法，在定位過程中所使用的場景資訊範圍與組織方式有所差異，而這些差異也會進一步影響提供給 VLM 的推理單位。

VLM-Grounder[6] 以預先取得、且具有相機位姿資訊的 RGB-D 觀測序列為基礎，並保留影像在掃描軌跡中的原始順序。系統會從中挑選包含目標類別的視角並進行整

理，再由 VLM 從這些場景觀測中辨識目標視角與目標物件。因此，其定位流程主要可視為一種以既有影像序列為基礎的場景層級視覺搜尋（scene-level visual search）。

相較之下，SeqVLM[7] 使用完整且經全域整合的三維場景表示及其對應的 RGB 影像。系統會先建立三維物件候選，並為每個候選關聯多個對應視角，在 VLM 推理之前便將場景資訊整理為物件層級的多視角表示（object-level multi-view representations）。這些候選共同形成後續的候選空間，VLM 再根據各候選的多視角資訊進行推理，以找出目標物件。由於候選在 VLM 推理之前就已於三維場景中建立，因此其空間範圍與跨視角對應關係都能在同一全域座標系中保持一致。

本研究同樣採用物件層級的推理方式，但改採**逐物件驗（object-wise verification）**的形式。系統會將不同視角下的 RGB-D 觀測逐步進行關聯，形成持續更新的潛在目標表示，而不是先建立完整且固定的三維候選集合。每一個潛在目標都會根據目前累積的多視角觀測與局部場景資訊進行獨立驗證，VLM 除了判斷該物件是否符合查詢中的條件，也會判斷現有視覺證據是否足以支持可靠的決策。透過這種方式，系統可以在場景資訊仍持續累積的過程中進行驗證，而不需要事先建立完整的場景表示。

2.3 視覺證據涵蓋與自適應觀測

除了場景資訊的組織方式之外，多視角觀測所涵蓋的視覺證據也是影響定位結果的重要因素。VLM-Grounder 與 SeqVLM[6], [7] 都是從既有的場景觀測中整理多視角資訊，而提供給 VLM 的內容主要由各自以目標為導向的視角選擇機制決定 [8, 14]。

VLM-Grounder 會保留偵測到目標類別的視角，並透過動態拼接（dynamic stitching）進行組織；SeqVLM 則根據三維候選在不同影像中的可見情況，建立各候選專屬的多視角表示。這些方法都能提供目標物件在不同角度下的互補資訊，但其觀測內容主要集中在已經包含目標類別或候選物件的視角，而不一定是根據目前尚未解決的語言條件所需要的證據來選擇。

當查詢只涉及物件類別或外觀特徵時，以目標為中心的多視角資訊通常能提供足夠的判斷依據；但若查詢同時包含參考物件或空間關係，僅觀察目標本身可能不足以完成完整驗證。因此，本研究進一步將視覺證據是否充分納入候選驗證流程。除了觀察潛在目標物件本身之外，系統也可以根據目前缺少的資訊擴展觀測範圍，取得候選周圍的場景影像，以補充參考物件及其與目標之間的空間關係。

因此，本研究的觀測範圍不再侷限於目標物件可見的視角，而是能根據候選驗證所需的視覺證據進行調整。當現有資訊不足時，系統會取得額外觀測並重新驗證；當證據已足以確認目標時，則可停止後續場景處理。此設計使多視角觀測由固定的目標導向方式，進一步轉變為依據驗證需求進行的自適應觀測。

三、方法與流程

3.1 系統架構




圖 2 PROVE-3D 整體系統流程

PROVE-3D 的整體流程如圖 2 所示，主要分為三個階段：觀測單元讀取與候選建立(Read Unit & Create Candidate)、候選精煉(Candidate Refinement)，以及 2D-to-3D 映射(2D-to-3D Mapping)。

在第一階段 **Read Unit & Create Candidate** 中，系統首先解析自然語言查詢，取得目標物件、目標屬性、參考物件及空間關係等資訊。接著以 Read Unit 為單位逐步讀取帶有相機位姿資訊的 RGB-D 觀測，並根據目標物件類別進行開放詞彙二維偵測。由於同一個實體物件可能出現在不同視角中，系統進一步利用跨視角特徵匹配，將不同影像中屬於同一物件的觀測進行關聯，逐步建立物件層級的候選表示。

第二階段為 **Candidate Refinement**。系統利用候選物件目前累積的多視角觀測，以及其周圍的場景資訊，交由 VLM 判斷該候選是否符合自然語言查詢。若現有證據足以確認候選，則可完成目標判定；若 VLM 判斷目前資訊仍不足，系統會根據缺少的視覺證據選擇額外觀測，更新候選後再次進行驗證。

第三階段為 **2D-to-3D Mapping**。當最終候選確定後，系統利用候選在不同視角中的分割遮罩、深度資訊、相機內參與相機位姿，將二維觀測反投影至三維空間。不同視角所得到的三維點會進一步融合與過濾，最後估計目標物件的三維邊界框。

3.2 觀測單元讀取與候選建立(Read Unit & Create Candidate)

給定自然語言查詢 q ，系統首先利用 VLM 將查詢拆解為目標資訊 $T = (t_o, t_a)$ 、參考資訊 $R = (r_o, r_a)$ ，以及空間關係 ρ ，表示為：

$$Q = (q, T, R, \rho) \quad (1)$$

其中， t_o 表示目標物件類別， t_a 表示目標屬性； r_o 與 r_a 分別表示參考物件及其屬性，而 ρ 則描述目標物件與參考物件之間的空間關係。目標物件 t_o 會作為開放詞彙二維偵測的語意提示，其餘資訊則保留至後續 Candidate Refinement 階段，用於判斷候選物件是否滿足完整查詢條件。

系統以 Read Unit 為單位逐步處理具有相機位姿資訊的 RGB-D 觀測。第 i 個視角表示為：

$$V_i = (I_i, D_i, T_i^{cw}, id_i) \quad (2)$$

其中， I_i 為 RGB 影像， D_i 為深度影像， T_i^{cw} 為相機座標系轉換至世界座標系的轉換矩陣，而 id_i 則表示該視角的識別資訊。此外，相機內參矩陣 K 會保留至後續的 2D-to-3D 投影階段使用。

當系統在影像中偵測到符合目標類別的物件後，每一個有效偵測結果會形成一個 *object view*：

$$u_{ij} = (V_i, d_{ij}, m_{ij}, id_{ij}) \quad (3)$$

其中， d_{ij} 為第 i 個視角中的第 j 個偵測結果， m_{ij} 為該物件對應的 segmentation mask；若當下尚未取得 mask，則可在需要時根據偵測框進一步產生。

由於同一個實體物件可能在不同視角中重複出現，因此系統利用 Cross-view Feature Matching 將屬於同一實體物件的 object views 關聯至同一候選物件。所有候選集合表示為：

$$C = \{c_1, c_2, \dots, c_M\} \quad (4)$$

每當新的 object view 加入時，系統會將其與目前已有的候選進行比較。若存在有效的跨視角配對，則將該觀測加入最佳匹配的候選中；若沒有符合條件的候選，則建立新的 candidate。藉由這種方式，不同視角中的物件觀測可以逐步累積成物件層級的多視角表示，供後續 Candidate Refinement 使用。

3.3 候選精煉 (Candidate Refinement)

Candidate Refinement 的目的，是利用候選物件累積的多視角資訊與周圍場景內容，判斷其是否符合自然語言查詢中的條件。

每個新建立的候選 c_i 初始設定為：

$$\text{status}(c_i) = \text{new} \quad (5)$$

並令：

$$\text{retry}(c_i) = 0 \quad (6)$$

每次進行驗證後，VLM 會將候選判定為 true、false 或 unsure。其中，true 表示目前的視覺證據支持該候選符合查詢；false 表示現有資訊與查詢條件不符；unsure 則表示目前所取得的證據仍不足以做出可靠判斷。

可進入驗證流程的候選集合定義為：

$$C_v = \{c_i \in C \mid \text{status}(c_i) \in \{\text{new}, \text{unsure}\} \wedge \text{retry}(c_i) < \tau_r\} \quad (7)$$

其中， $\text{retry}(c_i)$ 表示候選已進行的驗證次數， τ_r 則為允許的最大重試次數。每完成一次 VLM 驗證後，retry counter 會增加一次；若同時存在多個可驗證候選，系統會優先處理已累積較多 object views 的候選。

在第一次正式驗證之前，新 candidate 會先執行 Observe Environment，取得候選周圍的場景資訊，以補充參考物件與空間關係相關的視覺證據。系統將候選物件所在方向定義為 0° ，再加入其他相對方向的觀測，使 VLM 在第一次判斷時不只看到目標本身，也能取得部分周圍環境資訊。

若 VLM 的判斷結果為 unsure，則會進一步辨識目前缺少的證據，並從下列動作集合中選擇下一個動作：

$$a_i^t \in A = \{\text{Forward}, \text{Yaw}(\Delta\theta), \text{Stop}\} \quad (8)$$

其中，Forward 用於擴展以目標物件為中心的觀測，使系統取得更清楚或更完整的目標資訊；Yaw($\Delta\theta$) 則用於取得目標周圍較廣的場景資訊，以補充參考物件與空間關係所需的證據；Stop 表示停止目前候選的進一步精煉。當選擇 Forward 或 Yaw 時，系統會將新取得的觀測加入 candidate，並再次交由 VLM 進行驗證。

當所有候選完成處理後，若仍需要進行最終選擇，系統使用 FallbackSelect(C, Q)。候選會依照：

$$\text{true} > \text{unsure} > \text{false} \quad (9)$$

的優先順序選擇最高優先級的非空集合。若候選集合為空，則回傳 unresolved；若同一狀態中仍存在多個候選，則由 VLM 根據各候選的多視角觀測與查詢 Q 進行最終判斷。

本研究進一步設計 Early-stop 與 Full-scene 兩種搜尋策略。Early-stop 策略如 Algorithm 1 所示，當某個 candidate 被驗證為 true 後即直接回傳該候選，停止處理後續場景觀測；若所有觀測處理完成後仍沒有 true candidate，才使用 FallbackSelect 進行最終選擇。Full-scene 則不會因中途出現 true candidate 而停止，而是完整處理所有可用的場景觀測後，再進行最終候選選擇。完成候選選擇後，

最終候選 c^* 會送入 2D-to-3D Mapping 階段。

Algorithm 1 Early-stop Grounding in PROVE-3D

Require: Query Q , RGB-D observation source, retry limit τ_r

Ensure: Final candidate c^* or **unresolved**

```

1:  $C \leftarrow \emptyset$ 
2: while additional scene observations can be acquired do
3:   Acquire the next observation unit and update  $C$ 
4:   Refresh  $C_v$  using Eq. 2
5:   while  $C_v \neq \emptyset$  do
6:      $c_i \leftarrow \text{Select}(C_v)$ 
7:     if  $\text{status}(c_i) = \text{new}$  then
8:        $c_i \leftarrow \text{UpdateCandidate}(c_i, \text{ObserveEnvironment}(c_i))$ 
9:     end if
10:    repeat
11:       $(s_i, a_i) \leftarrow \text{Verify}(c_i, Q)$ 
12:       $\text{status}(c_i) \leftarrow s_i, \text{retry}(c_i) \leftarrow \text{retry}(c_i) + 1$ 
13:      if  $s_i = \text{true}$  then
14:        return  $\text{Finalize}(c_i)$  ▷ Early-stop
15:      else if  $s_i = \text{unsure}$  and  $\text{retry}(c_i) < \tau_r$  and  $a_i \neq \text{Stop}$  then
16:         $c_i \leftarrow \text{UpdateCandidate}(c_i, \text{Acquire}(c_i, a_i))$ 
17:      end if
18:    until  $s_i \neq \text{unsure}$  or  $a_i = \text{Stop}$  or  $\text{retry}(c_i) \geq \tau_r$ 
19:     $C_v \leftarrow C_v \setminus \{c_i\}$ 
20:  end while
21: end while
22: return  $\text{FallbackSelect}(C, Q)$ 

```

3.4 2D-to-3D 映射 (2D-to-3D Mapping)

當最終候選 c_k 確定後，系統會將該候選所包含的有效 object views 映射至共同的三維空間。

對每一個 object view，首先將其 segmentation mask 與對應的深度影像 D_i 、相機內參矩陣 K ，以及 camera-to-world transformation T_i^{cw} 結合，將 mask 範圍內的二維像素反投影成三維點。若資料集另外提供 alignment matrix A ，則會再將投影後的三維點轉換至對齊後的場景座標系。

候選 c_k 所包含的所有有效 object views 之三維點集合會進一步融合為：

$$P_{all}^{3D} = \bigcup_{u_{ij} \in U_k} P_{ij}^{3D} \quad (10)$$

其中， U_k 表示 candidate c_k 所包含的 object-view 集合。

由於 segmentation error 與 depth noise 可能在反投影過程中產生離群點，因此系統會對融合後的三維點進行過濾：

$$P_k^{3D} = \text{FilterPoints}(P_{all}^{3D}) \quad (11)$$

最後，根據過濾後的點雲估計三維邊界框：

$$B_k^{3D} = \text{BBox}((P_k^{3D})_{xy}, (P_{all}^{3D})_z) \quad (12)$$

其中， x 與 y 方向使用過濾後的點雲範圍，以降低水平方向離群點造成的影響； z 方向則保留原始融合點雲的範圍，避免過度過濾造成物件垂直高度被截斷。最終得到的 B_k^{3D} 即為系統輸出的目標物件三維邊界框。

四、實驗結果

4.1 實驗設定

4.1.1 資料集與評估指標

本研究於 ScanRefer[3] 與 Nr3D[1] 兩個三維視覺定位資料集上進行實驗，兩個 benchmark 各使用 250 筆 validation samples。

ScanRefer 採用三維交並比 (3D Intersection over Union, 3D IoU) 作為評估依據，並以 Acc@0.25 與 Acc@0.5 作為主要指標，同時將測試樣本區分為 Unique 與 Multiple。Unique 表示場景中只有一個符合目標類別的物件，而 Multiple 則表示場景中存在多個相同類別物件，因此需要依賴額外屬性或空間關係進行區分。

Nr3D 則採用 top-1 accuracy 作為主要評估指標，並進一步區分為 Easy / Hard 與 View-Dependent / View-Independent。由於 PROVE-3D 直接輸出三維邊界框，因此在 Nr3D 評估時，會將預測結果與邊界框中心位置最近的標註物件進行配對；若該物件的 instance ID 與 ground-truth target 相同，則視為定位正確。若查詢未能產生有效預測結果，則計為錯誤。Ground-truth bounding box 僅用於最終評估，不參與實際的 grounding 過程。

4.1.2 實作設定

本研究使用 YOLOE[13] 進行開放詞彙物件偵測，使用 SAM[14] 產生物件分割遮罩，並以 PATS[15] 進行跨視角特徵匹配；視覺語言模型則採用 GPT-5.4[16]。所有模組皆直接使用預訓練模型，不針對本研究任務進行額外微調。

每個 Read Unit 包含 10 張影像，候選驗證的最大重試次數設定為：

$$\tau_r = 2$$

Full-scene 與 Early-stop 使用相同的查詢集合與初始影像取樣方式，模型設定及 2D-to-3D Mapping 流程亦完全相同，兩者唯一差異為搜尋終止策略。

4.1.3 視角選擇設定

由於 ScanRefer 與 Nr3D 提供的是預先錄製且具有相機位姿資訊的 RGB-D 影像，因此本研究中的視角動作並非實際控制相機移動，而是從既有觀測中選擇符合條件的影像。

在 Observe Environment 階段，系統會從候選物件 1.0 公尺範圍內，以 45° 為間隔取得周圍視角。當候選被 VLM 判定為 unsure 時，Yaw 會在 1.0 公尺範圍內搜尋 $\pm 60^\circ$ 的視角，並以 15° 為間隔選取觀測。

Forward 則會先利用目前候選的二維遮罩、深度資訊、相機內參與位姿，估計其暫時性的三維位置，再從可用觀測中搜尋較適合的視角，並優先考量物件可見度、影像涵蓋比例、物件尺度及視角多樣性。

4.2 三維視覺定位結果

本研究將 PROVE-3D 與具代表性的零樣本三維視覺定位方法進行比較。其中，VLM-Grounder [6] 與本研究同樣採用以影像為主的定位方式，因此作為主要比較對象；此外，也納入使用 3D 或 2D+3D 場景資訊的方法，以提供較完整的比較。

4.2.1 ScanRefer 實驗結果

表 2 ScanRefer 三維視覺定位結果 (%)

方法	輸入	Unique		Multiple		Overall	
		Acc@0.25	Acc@0.5	Acc@0.25	Acc@0.5	Acc@0.25	Acc@0.5
LLM-Grounder [17]	3D	–	–	–	–	17.1	5.3
ZS3DVG [8]	2D+3D	63.8	58.4	27.7	24.6	36.4	32.7
VLM-Grounder [6]	2D	66.0	29.8	48.3	33.5	51.6	32.8
SeeGround [5]	2D+3D	75.7	68.9	34.0	30.0	44.1	39.4
SeqVLM [7]	2D+3D	77.3	72.7	47.8	41.3	55.6	49.6
Ours (Full-scene)	2D	72.8	46.7	44.3	34.2	54.8	38.8
Ours (Early-stop)	2D	70.7	48.9	41.8	33.5	52.4	39.2

其中，2D 表示主要以影像進行 grounding，3D 表示使用預先建立的三維場景表示，而 2D+3D 則同時結合兩種資訊；即使輸入標示為 2D，深度資訊仍可用於最終的三維投影。

由表中結果可看出，在相近的 image-based grounding 設定下，PROVE-3D 具有良好的競爭力。與 VLM-Grounder 相比，Full-scene 在 Unique、Overall，以及 Multiple Acc@0.5 上皆取得較佳結果，而 Multiple Acc@0.25 則仍低於

VLM-Grounder。此外，在不使用預先建立的三維物件候選情況下，Full-scene 的 Overall Acc@0.25 達到 54.8%，接近 SeqVLM 的 55.6%。

在 Multiple 類型查詢中，由於場景內存在多個相同類別物件，需要進一步依賴屬性、參考物件或空間關係加以區分，因此整體難度較高。本研究目前主要採用逐候選獨立驗證，而非對所有候選進行聯合比較，這也是 Multiple 表現相對受限的原因之一。此外，Acc@0.5 對三維邊界框精度要求較高，因此更容易受到 segmentation、depth 與多視角投影誤差影響。

在 Multiple 類型查詢中，由於場景內存在多個相同類別物件，需要進一步依賴屬性、參考物件或空間關係加以區分，因此整體難度較高。本研究目前主要採用逐候選獨立驗證，而非對所有候選進行聯合比較，這也是 Multiple 表現相對受限的原因之一。此外，Acc@0.5 對三維邊界框精度要求較高，因此更容易受到 segmentation、depth 與多視角投影誤差影響。

4.2.2 Nr3D 實驗結果

表 3 Nr3D 三維視覺定位結果 (%)

方法	輸入	Easy	Hard	Dep.	Indep.	Overall
ZS3DVG [8]	2D+3D	46.5	31.7	36.8	40.0	39.0
SeeGround [5]	2D+3D	54.5	38.3	42.3	48.2	46.1
VLM-Grounder [6]	2D	55.2	39.5	45.8	49.4	48.0
SeqVLM [7]	2D+3D	58.1	47.4	51.0	54.5	53.2
Ours (Full-scene)	2D	60.0	51.3	60.6	53.2	55.6
Ours (Early-stop)	2D	54.4	47.4	55.2	48.7	51.2

在 Nr3D 上，PROVE-3D 的 Full-scene 取得 55.6% 的 Overall accuracy，為表中所有比較方法中最高，同時在 Easy、Hard 與 View-Dependent 三類查詢中取得最佳結果。

其中，View-Dependent 的表現最為明顯，Full-scene 達到 60.6%，相較 SeqVLM 的 51.0% 提升 9.6 個百分點。這顯示當語言描述需要額外的視角與空間關係資訊時，取得更廣泛的場景上下文有助於提高定位能力。在 View-Independent 查詢上，PROVE-3D 仍與最佳方法維持相近表現，說明本方法的主要優勢較集中於需要額外空間上下文才能完成判斷的查詢。

Early-stop 雖然會在完整處理所有觀測之前終止搜尋，其 Overall accuracy 仍達到 51.2%，並高於 VLM-Grounder 的 48.0%，顯示即使減少場景處理量，仍能維持一定的定位能力。

4.3 Early-stop 策略分析

Early-stop 主要用於評估在未處理完所有可用場景觀測的情況下，系統是否仍能完成三維視覺定位。在 ScanRefer 上，Full-scene 的 Overall Acc@0.25 為 54.8%，採用 Early-stop 後下降至 52.4%；在 Nr3D 上，整體準確率則由 55.6% 降至 51.2%。整體而言，Early-stop 雖然會造成一定程度的準確率下降，但仍能維持相近的定位表現。




圖 3 Early-stop 相對於 Full-scene 的觀測量與準確率保留比例

4.3.1 觀測效率

為衡量 Early-stop 的觀測效率，本研究同時考慮 Read Unit 實際處理影像數量相對於場景中全部有效影像的比例，以及相對於 Full-scene Read Unit 觀測量的比例。

相對於所有有效 posed images 的 Read Unit 觀測比例定義為：

$$R_{valid} = \frac{N_{read}^{Early}}{N_{valid}} \quad (13)$$

其中， N_{read}^{Early} 表示 Early-stop 實際透過 Read Unit 處理的場景影像數， N_{valid} 則表示場景中所有有效 posed images 的數量。

實驗結果顯示，Early-stop 平均只需處理全部有效 posed images 的 31.70%。在與 Full-scene 採用相同初始取樣的情況下，Early-stop 僅使用 Full-scene 62.93% 的 Read Unit 觀測量，相當於減少 37.07% 的 Read Unit observations，同時仍能保留 Full-scene 95.62% 的 Acc@0.25 表現。

需要注意的是，此處的 Read Unit observation 統計並不包含 Observe Environment 與後續 Additional Observation Selection 所取得的視角。此外，約有 60% 的測試案例會在全部預先取樣的 Read Unit observations 處理完成之前終止，說明部分查詢不需要完整處理初始觀測序列即可完成定位。

4.4 三維定位精度分析

為分析在更嚴格 IoU 條件下的三維定位品質，本研究定義 Strict-IoU Retention Ratio：

$$R_{loc} = \frac{Acc@0.5}{Acc@0.25} \quad (14)$$

當 R_{loc} 越高，代表在 IoU 0.25 條件下判定正確的預測中，有較高比例仍能符合更嚴格的 IoU 0.5 條件。

表 4 ScanRefer Strict-IoU Retention Ratio (%)

方法	Unique	Multiple	Overall
VLM-Grounder	0.45	0.69	0.63
Ours (Full-scene)	0.64	0.77	0.71
Ours (Early-stop)	0.69	0.80	0.75

如表 3 所示，PROVE-3D 的兩種設定皆取得高於 VLM-Grounder 的 Strict-IoU 保留率，其中在 Unique 類型上的提升最為明顯。這表示在 IoU 0.25 下已正確定位的預測中，PROVE-3D 有較高比例仍能在更嚴格的 IoU 0.5 條件下維持正確，說明當目標區域已被辨識後，本方法具有較穩定的三維定位表現。

不過， R_{loc} 仍應與實際的 grounding 指標一併解讀。Full-scene 的 Overall Acc@0.25 高於 Early-stop (54.8% 對 52.4%)，但 Early-stop 的 Acc@0.5 略高於 Full-scene (39.2% 對 38.8%)，同時具有較高的保留率 (0.75 對 0.71)。這反映出兩種策略在較寬鬆的定位覆蓋能力與較嚴格的定位精度之間存在一定取捨：Full-scene 在較寬鬆的 IoU 門檻下能正確定位更多目標，而 Early-stop 則能讓較高比例的成功預測在更嚴格的 IoU 條件下仍維持正確。

4.5 消融實驗

本研究所有消融實驗皆在 Nr3D 的 Early-stop 設定下進行。

4.5.1 元件貢獻

表 5 元件消融實驗 (%)

Removed	Accuracy
Cross-view Feature Matching	38.4
Observe Environment	50.4
Additional Observation	47.6
None (all components)	51.2

表 4 用於評估各主要元件對系統效能的影響。當移除 Cross-view Feature Matching 後，不同 Read Unit 影像中的 object views 將不再進行跨視角關聯；每個 candidate 僅由單一偵測到的 object view 建立，並獨立進行後續 refinement，因此不再使用跨視角 candidate set CC 與 FallbackSelect(C,Q)。

移除 Observe Environment 後，系統不再於初次驗證前蒐集候選周圍的環境觀測；而移除 Additional Observations 則代表當 VLM 判定為 unsure 後，不再進一步取得新的視覺證據，也不執行重新驗證。

實驗結果顯示，Cross-view Feature Matching 對整體效能的影響最大；此外，Additional Observations 亦能有效提升 candidate verification 的效果。完整系統配置取得最高的準確率。

4.5.2 環境證據分析

表 6 環境證據消融實驗 (%)

Environment	Action	Accuracy
No	Fixed Forward	46.0
Yes	Fixed Forward	48.0
No	Suggested	50.4
Yes	Suggested	51.2

表 5 用於分析：除了能看見目標物件的視角之外，周圍環境觀測是否也能提升 grounding 效果。Forward 會根據投影後的目標位置選擇視角，因此主要保留能清楚觀察目標的影像；相較之下，Observe Environment 與 Yaw 則依據相機位姿限制取得周圍視角，並不要求目標物件必須持續出現在畫面中。

實驗結果顯示，這些周圍視角能補充與參考物件及空間關係相關的視覺證據，支持本研究的核心動機：對 grounding 有幫助的視覺證據，並不僅限於包含目標物件的視角。

4.5.3 動作選擇策略

表 7 額外觀測動作選擇策略消融實驗 (%)

Strategy	Accuracy
Fixed Forward	48.0
Fixed Yaw	48.4
Random	49.2
Suggested Action	51.2

表 6 單獨比較額外觀測的動作選擇策略，其餘系統設定皆保持不變。Fixed Forward 與 Fixed Yaw 分別固定執行對應動作；Random 則在 Forward 與 Yaw 之間隨機選擇，而不考慮目前缺少的視覺證據；Suggested Action 則根據尚未解決的證據需求選擇下一步觀測方向。

結果顯示，Suggested Action 的表現優於固定策略與隨機策略，說明根據目前缺失的視覺證據選擇觀測方向，能更有效地支援候選驗證。

五、結論與未來展望

我們提出了 PROVE-3D，一個漸進式的零樣本三維視覺定位框架，整合了跨視角候選物件建構（cross-view candidate construction）、基於證據的驗證（evidence-based verification）以及額外觀測視角選擇（additional observation selection）。

透過在場景處理過程中逐步驗證候選物件，PROVE-3D 能夠實現基於證據的提前停止（Early-stop）機制，同時在 ScanRefer 與 Nr3D 資料集上維持具競爭力的表現。實驗與消融實驗結果顯示，漸進式候選物件驗證以及證據引導的觀測選擇，對零樣本三維視覺定位具有良好的效果。

然而，本框架仍存在一些限制。由於目前主要是對每個候選物件進行獨立驗證，因此在區分場景中多個同類別物件時仍可能遇到困難。此外，最終三維邊界框（3D bounding box）的準確度仍容易受到影像分割、深度資訊以及投影誤差的影響。未來，我們將進一步研究候選物件之間的聯合推理（joint reasoning across candidates），以及更穩健的三維定位方法，以進一步提升系統在複雜場景中的視覺定位能力。

參考文獻

- [1] P. Achlioptas, A. Abdelreheem, F. Xia, M. Elhoseiny, and L. Guibas, “ReferIt3D: Neural Listeners for Fine-Grained 3D Object Identification in Real-World Scenes,” *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 12346 LNCS, pp. 422–440, 2020, doi: 10.1007/978-3-030-58452-8_25/SAVE-RESEARCH.
- [2] Q. Yuan, J. Zhang, K. Li, and R. Stiefelhagen, “Solving Zero-Shot 3D Visual Grounding as Constraint Satisfaction Problems,” Nov. 2024, Accessed: Jan. 28, 2026. [Online]. Available: <https://arxiv.org/pdf/2411.14594>
- [3] D. Z. Chen, A. X. Chang, and M. Nießner, “ScanRefer: 3D Object Localization in RGB-D Scans using Natural Language,” *Lecture Notes in Computer Science (including subseries Lecture Notes in Artificial Intelligence and Lecture Notes in Bioinformatics)*, vol. 12365 LNCS, pp. 202–221, Dec. 2019, doi: 10.1007/978-3-030-58565-5_13.
- [4] Y. Wu, X. Cheng, R. Zhang, Z. Cheng, and J. Zhang, “EDA: Explicit Text-Decoupling and Dense Alignment for 3D Visual Grounding,” *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 2023-June, pp. 19231–19242, Apr. 2023, doi: 10.1109/CVPR52729.2023.01843.
- [5] R. Li, S. Li, L. Kong, X. Yang, and J. Liang, “SeeGround: See and Ground for Zero-Shot Open-Vocabulary 3D Visual Grounding,” *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pp. 3707–3717, Dec. 2024, doi: 10.1109/CVPR52734.2025.00351.
- [6] R. Xu, Z. Huang, T. Wang, Y. Chen, J. Pang, and D. Lin, “VLM-Grounder: A VLM Agent for Zero-Shot 3D Visual Grounding,” *Proc. Mach. Learn. Res.*, vol. 270, pp. 3961–3985, Oct. 2024, Accessed: Jan. 27, 2026. [Online]. Available: <https://arxiv.org/pdf/2410.13860>
- [7] J. Lin *et al.*, “SeqVLM: Proposal-Guided Multi-View Sequences Reasoning via VLM for Zero-Shot 3D Visual Grounding,” *Proceedings of the 33rd ACM International Conference on Multimedia (MM ’25), October 27–31, 2025, Dublin, Ireland*, vol. 1, Aug. 2025, doi: 10.1145/3746027.3754985.
- [8] Z. Yuan, J. Ren, C. M. Feng, H. Zhao, S. Cui, and Z. Li, “Visual Programming for Zero-shot Open-Vocabulary 3D Visual Grounding,” *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, pp. 20623–20633, Nov. 2023, doi: 10.1109/CVPR52733.2024.01949.
- [9] Z. Jin *et al.*, “SPAZER: Spatial-Semantic Progressive Reasoning Agent for Zero-shot 3D Visual Grounding,” Jun. 2025, Accessed: Sep. 16, 2026. [Online]. Available: <https://arxiv.org/pdf/2506.21924>
- [10] N. Drozdov, A. Lemeshko, N. Gavrilov, A. Konushin, D. Rukhovich, and M.

- Kolodiazhnyi, "Z3D: Zero-Shot 3D Visual Grounding from Images," Feb. 2026, Accessed: Sep. 16, 2026. [Online]. Available: <https://arxiv.org/pdf/2602.03361>
- [11] H. Wang, Z. Lin, Z. Xu, and L. Huang, "Think, Act, Build: An Agentic Framework with Vision Language Models for Zero-Shot 3D Visual Grounding," Apr. 2026, Accessed: Sep. 16, 2026. [Online]. Available: <https://arxiv.org/pdf/2604.00528>
- [12] C. Huynh, M. Popov, D. Gridusov, and S. Kolyubin, "AgentGrounder: Zero-Shot 3D Visual Pointcloud Grounding using Multimodal Language Models," May 2026, Accessed: Sep. 16, 2026. [Online]. Available: <https://arxiv.org/pdf/2605.25901>
- [13] A. Wang, L. Liu, H. Chen, Z. Lin, J. Han, and G. Ding, "YOLOE: Real-Time Seeing Anything," pp. 24591–24602, Mar. 2025, doi: 10.1109/iccv51701.2025.02280.
- [14] A. Kirillov *et al.*, "Segment Anything," *Proceedings of the IEEE International Conference on Computer Vision*, pp. 3992–4003, Apr. 2023, doi: 10.1109/ICCV51070.2023.00371.
- [15] J. Ni *et al.*, "PATS: Patch Area Transportation with Subdivision for Local Feature Matching," *Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition*, vol. 2023-June, pp. 17776–17786, Mar. 2023, doi: 10.1109/CVPR52729.2023.01705.
- [16] "GPT-5.4 登場 | OpenAI." Accessed: Sep. 16, 2026. [Online]. Available: <https://openai.com/zh-Hant/index/introducing-gpt-5-4/>
- [17] J. Yang *et al.*, "LLM-Grounder: Open-Vocabulary 3D Visual Grounding with Large Language Model as an Agent," *Proc. IEEE Int. Conf. Robot. Autom.*, pp. 7694–7701, Sep. 2023, doi: 10.1109/ICRA57147.2024.10610443.

附錄

A.1 跨視角特徵匹配 (Cross-view Feature Matching)

跨視角特徵匹配會將每個新加入的物件視角 (object view)，與所有既有候選物件中具有代表性的最佳物件視角進行比較。為避免對明顯不相容的候選物件進行不必要的特徵匹配，當候選物件具有暫時性的三維邊界框 (provisional 3D box) 時，系統會先利用該邊界框，在目前輸入視角中進行幾何投影預檢 (geometric projection precheck)。

具體而言，系統會將候選物件的暫時性三維邊界框投影至新加入的視角中。只有當投影得到的二維邊界框有效，且該投影框與新輸入的二維邊界框有所重疊，或兩者的二維中心距離不超過 200 pixels 時，才會保留該候選物件進行後續匹配。接著，特徵匹配器會在新輸入的物件視角與候選物件的代表視角之間建立點對應關係 (point correspondences)。這些對應點會依序利用候選端代表視角的邊界框，以及新輸入視角的邊界框進行過濾。若代表視角具有物件分割遮罩 (object mask)，則候選端的匹配點還會進一步依據該遮罩進行篩選，並要求這些匹配點反投影後所形成的物件區域，與新輸入視角中的物件區域保持足夠的一致性。

在實作中，此一致性判定需滿足以下條件：原始匹配點數量需大於 1000、經邊界框過濾後的匹配點數量需大於 100、遮罩反投影覆蓋率 (mask back-projected coverage) 至少為 0.8；當候選物件具有遮罩時，遮罩反投影支持比例 (mask back-projected support ratio) 亦須至少達到 1/3。如 Algorithm 2 所示，跨視角關聯流程以較抽象的方式表示為一個類似分數的量 s_k ，以及接受閾值 τ 。在實際實作中，條件 $s_k > \tau$ 表示該候選物件已通過前述投影框預檢以及特徵對應點過濾等匹配接受條件。而 $k^* = \arg \max s_k$ 則表示在所有有效匹配結果中，選擇經過過濾後匹配點數量最多的候選物件；若匹配點數量相同，則再以總匹配點數量作為決勝依據。在此設計中，暫時性的三維幾何資訊僅作為候選物件跨視角關聯的輔助線索，而不作為最終的三維視覺定位結果。最終的三維預測邊界框 B_k^{3D} 會在後續的 2D-to-3D Mapping 階段中產生。在暫時性三維幾何重建以及候選物件匹配的整個過程中，皆不使用任何 ground-truth 三維位置、ground-truth bounding box 或目標物件標註資訊。

Algorithm 2 Cross-view Feature Matching

Input: New object view $u_{i,j} = (V_i, d_{i,j}, m_{i,j}, \text{id}_{i,j})$;
Candidate set $C = c_1, c_2, \dots, c_K$;
Matching threshold τ
Output: Updated candidate set C

```
1:  $\mathcal{M} \leftarrow \emptyset$ 
2: for all candidate  $c_k \in C$  do
3:   if  $c_k$  has a provisional 3D box  $B_k^{\text{prov}}$  then
4:      $\hat{b}_k \leftarrow \text{Project}(B_k^{\text{prov}}, V_i)$ 
5:     if  $\hat{b}_k$  is invalid then
6:       continue
7:     end if
8:     if  $\hat{b}_k$  fails the projected-overlap / center-distance precheck then
9:       continue
10:    end if
11:  end if
12:   $s_k \leftarrow \text{CrossViewMatch}(u_{i,j}, c_k)$ 
13:  if  $s_k > \tau$  then
14:     $\mathcal{M} \leftarrow \mathcal{M} \cup \{(k, s_k)\}$ 
15:  end if
16: end for
17: if  $\mathcal{M} \neq \emptyset$  then
18:    $k^* \leftarrow \arg \max_{(k, s_k) \in \mathcal{M}} s_k$ 
19:    $U_{k^*} \leftarrow U_{k^*} \cup \{u_{i,j}\}$ 
20:   Update representative object view of  $c_{k^*}$ 
21: else
22:    $c_{\text{new}} \leftarrow \text{CreateCandidate}(u_{i,j})$ 
23:    $C \leftarrow C \cup \{c_{\text{new}}\}$ 
24: end if
25: return  $C$ 
```

A.2 2D-to-3D 映射 (2D-to-3D Mapping)

完整的候選物件層級 2D-to-3D 映射流程如下所示。

Algorithm 3 2D-to-3D Mapping

Require: Candidate c_k with object-view set U_k , intrinsic matrix K , optional alignment matrix A

Ensure: Filtered 3D point set $\mathcal{P}_k^{3D}$ and 3D bounding box B_k^{3D}

```

1:  $\mathcal{P}_{\text{all}}^{3D} \leftarrow \emptyset$ 
2: for all  $u_{ij} \in U_k$  do
3:   if  $u_{ij}$  is inactive or  $D_i$  or  $T_i^{cw}$  is unavailable then
4:     continue
5:   end if
6:   if  $m_{ij}$  is unavailable then
7:      $m_{ij} \leftarrow \text{ObtainMask}(u_{ij})$ 
8:   end if
9:   if  $m_{ij}$  is unavailable then
10:    continue
11:  end if
12:   $\mathcal{P}_{ij}^{3D} \leftarrow \text{BackProject}(m_{ij}, D_i, K)$ 
13:   $\mathcal{P}_{ij}^{3D} \leftarrow \text{Transform}(\mathcal{P}_{ij}^{3D}, T_i^{cw})$ 
14:  if  $A$  is available then
15:     $\mathcal{P}_{ij}^{3D} \leftarrow \text{Align}(\mathcal{P}_{ij}^{3D}, A)$ 
16:  end if
17:   $\mathcal{P}_{\text{all}}^{3D} \leftarrow \mathcal{P}_{\text{all}}^{3D} \cup \mathcal{P}_{ij}^{3D}$ 
18: end for
19: if  $\mathcal{P}_{\text{all}}^{3D} = \emptyset$  then
20:   return failure
21: end if
22:  $\mathcal{P}_k^{3D} \leftarrow \text{FilterPoints}(\mathcal{P}_{\text{all}}^{3D})$ 
23:  $B_k^{3D} \leftarrow \text{BBox}((\mathcal{P}_k^{3D})^{xy}, (\mathcal{P}_{\text{all}}^{3D})^z)$ 
24:  $c_k.\text{points3d} \leftarrow \mathcal{P}_k^{3D}$ 
25:  $c_k.\text{bbox3d} \leftarrow B_k^{3D}$ 
26: return  $\mathcal{P}_k^{3D}, B_k^{3D}$ 

```
